

# Projet *graph neural net* Présentation - MAP583

Nathanaël Cuvelle-Magar, Mathieu Guesmi, Yongyi Hu

8 mars 2022

# Plan

- 1 Introduction
- 2 Ré-obtention des résultats pour les FGNN
- 3 Généralisation sur le type de graphe
- 4 Généralisation sur le nombre de sommets
- 5 Conclusion
- 6 References et annexes

# Introduction - Quadratic Assignment Problem

## Notations

- Given two finite sets  $P$  and  $L$
- Weight function  $w : P \times P \longrightarrow \mathbb{R}$
- Distance function  $d : L \times L \longrightarrow \mathbb{R}$

## Objective

$$\min_{\substack{f: P \rightarrow L \\ \text{bijection}}} \sum_{a, b \in P} w(a, b) \cdot d(f(a), f(b)) \quad (1)$$

## Original Situation

- $P$  - Facilities;  $L$  - Locations
- $w(a, b)$  - Amount of goods to transfer
- $d(f(a), f(b))$  - Distance between the factories

# Introduction - Network Alignment

## Problem

Find the "best" mapping between the vertices of two graphs.

## Objective

$$\max_{\sigma \in S_n} \sum_{i,j \in [n]} A_{ij} \cdot B_{\sigma(i), \sigma(j)} \quad (2)$$

where  $A$ ,  $B$  are separately the adjacency matrix for two graphs of dimension  $n \times n$ ,  $S_n$   $n$ -permutation set.

## Relation with QAP

Comparing the Eqn. (1) and (2), the Network Alignment problem is a special case of Quadratic Alignment Problem under this setting.

# Plan

- 1 Introduction
- 2 Ré-obtention des résultats pour les FGNN
- 3 Généralisation sur le type de graphe
- 4 Généralisation sur le nombre de sommets
- 5 Conclusion
- 6 References et annexes

# Architecture du code pour la résolution du QAP

## Idée générale

- Utilisation d'un *GNN* siamois pour encoder les noeuds des graphes à aligner.
- En multipliant les plongements obtenus pour les deux graphes, on obtient une matrice de similarité sur les noeuds.
- On obtient finalement une permutation sur les indexes en résolvant un problème d'affectation.

The diagram illustrates the process of node embedding and similarity matrix calculation. It shows two input graphs,  $G_1$  and  $G_2$ , both of size  $n^2 \times a$ . Each graph is processed by a GNN  $\mathcal{N}$  to produce an embedding matrix,  $E_1$  and  $E_2$ , both of size  $n \times b$ . These two embedding matrices are then multiplied together to produce a similarity matrix  $E_1 E_2^T$  of size  $n^2$ .



$$\begin{array}{ccc} G_1 \in \mathbb{R}^{n^2 \times a} & \xrightarrow{\text{GNN } \mathcal{N}} & E_1 \in \mathbb{R}^{n \times b} \\ & & \searrow \\ & & E_1 E_2^T \in \mathbb{R}^{n^2} \\ & \nearrow & \\ G_2 \in \mathbb{R}^{n^2 \times a} & \xrightarrow{\text{GNN } \mathcal{N}} & E_2 \in \mathbb{R}^{n \times b} \end{array}$$

Figure – [AL21]

# Exécution sur Google Colab

## Apports

- Rédaction d'un notebook pour exécution avec les GPUs disponibles sur Google Colab.
- Adaptation du code d'un notebook existant pour l'affichage des résultats.



# Plan

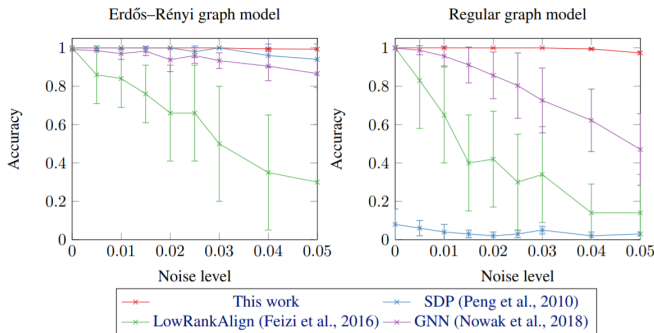
- 1 Introduction
- 2 Ré-obtention des résultats pour les FGNN
- 3 Généralisation sur le type de graphe**
- 4 Généralisation sur le nombre de sommets
- 5 Conclusion
- 6 References et annexes



# Comparaisons between Regular and Erdos Reyni

## Observations


- Regular generated graphs are more complicated to be aligned than Erdos Reyni ones for our problem.
- It does not seem to depend to the algorithm.




# Changing the graph generator

## Observations

- We observe the previous phenomenon with our algorithm.
- The training on Regular generated graphs is more generalizable than that on Erdos-Reyni ones.



(c) Train - Regular, Test - ER




(d) Train - ER, Tested - Regular


# Plan

- 1 Introduction
- 2 Ré-obtention des résultats pour les FGNN
- 3 Généralisation sur le type de graphe
- 4 Généralisation sur le nombre de sommets**
- 5 Conclusion
- 6 References et annexes


# Different number of nodes




(e)  $|V| = 25$ ,  $d = 0.2$



(f)  $|V| = 50$ ,  $d = 0.2$




(g)  $|V| = 100$ ,  $d = 0.2$




(h)  $|V| = 200$ ,  $d = 0.2$


# Same average degree




(i)  $|V| = 25, d = 0.4$



(j)  $|V| = 50, d = 0.2$



(k)  $|V| = 100, d = 0.1$



(l)  $|V| = 200, d = 0.05$

# Plan

- 1 Introduction
- 2 Ré-obtention des résultats pour les FGNN
- 3 Généralisation sur le type de graphe
- 4 Généralisation sur le nombre de sommets
- 5 Conclusion**
- 6 References et annexes

# Conclusion

## Résultats

- ➊ Reproduction des résultats présentés dans le papier original ;
- ➋ Unification de la phase d'apprentissage (sur GPU Google Colab) et de l'affichage des résultats sur un seul jupyter notebook ;
- ➌ Étude des capacités de généralisation du modèle en termes de type de graphes et de nombre/densité de sommets.

## Travaux futurs

Trouver une normalisation permettant une meilleure capacité de généralisation du réseau quant aux modifications du nombre de noeuds ou de la densité des arêtes.

# Plan

- 1 Introduction
- 2 Ré-obtention des résultats pour les FGNN
- 3 Généralisation sur le type de graphe
- 4 Généralisation sur le nombre de sommets
- 5 Conclusion
- 6 References et annexes**



# References I



Waïss Azizian and Marc Lelarge, *Expressive power of invariant and equivariant graph neural networks*, International Conference on Learning Representations, 2021.